

第6章 Dremel | 开卷速查版

本章一句话： **Dremel** 是 Google 用来做超大规模嵌套数据交互式分析的系统。它的核心难点是：数据原本是嵌套记录，但为了查询快，要按 **列式存储**；列式拆开以后，还要能靠 **repetition level / definition level** 把结构拼回去。🌟

常考题型： 给嵌套数据表，要求给某一列填 **r / d**；给列式数据，要求基于 **FSM** 拼回记录；解释 **r** 和 **d** 的含义；解释为什么 Dremel 能只读部分列还保留嵌套结构。

翻页关键词： Nested data model → repeated / optional / required → Column-striped representation → r/d → Code/Country例子 → Encoding → Record assembly FSM → 拼回表。

1. Dremel 解决什么问题

Dremel 面向的是 **web-scale datasets**，也就是万亿级记录、多 TB 数据，目标是做交互式分析查询。PPT里列出它的特点：支持 trillion-record / multi-terabyte datasets、可扩展到 thousands of nodes、fault tolerant execution、nested data model、columnar storage and processing、tree architecture。

它要解决的问题可以压成一句话：

原始数据是复杂嵌套结构，但查询时常常只需要其中几列；如果整行读，会浪费 I/O；如果按列存，又会丢失嵌套结构。**Dremel** 用 **r/d** 两个 level 在列式存储中保留嵌套结构。

考试写法： Dremel 是用于大规模嵌套数据交互式分析的系统。它采用列式存储来减少查询时读取的数据量，同时为每个值保存 repetition level 和 definition level，从而在只读取部分字段的情况下仍能恢复原来的嵌套记录结构。

2. Nested Data Model：嵌套数据模型

Dremel 的数据不是普通二维表，而是 **strongly typed nested record**，即强类型嵌套记录。每个字段可以是原子类型，也可以是 record/group。

PPT里有三种字段修饰：

required：必须出现，不能缺失。**optional / ?**：可选字段，可以出现，也可以为空。***repeated / :** 重复字段，可以出现 0 次、1 次或多次。

PPT示例 schema 是：

```
message Document {
  required int64 DocId;

  optional group Links {
    repeated int64 Backward;
    repeated int64 Forward;
  }

  repeated group Name {
    repeated group Language {
```

```

        required string Code;
        optional string Country;
    }
    optional string Url;
}
}

```

简单理解：

DocId：每条记录必须有一个。**Links**：可选，有可能没有。**Backward / Forward**：在 Links 里面可以重复多次。**Name**：一个 Document 可以有多个 Name。**Language**：一个 Name 下面可以有多个 Language。**Code**：Language 里必须有。**Country**：Language 里可选。**Url**：Name 里可选。

3. 为什么列式存储会有问题

普通行式记录长这样：

```

DocId: 10
Links:
  Forward: 20
  Forward: 40
  Forward: 60
Name:
  Language:
    Code: en-us
    Country: us
  Language:
    Code: en
    Url: http://A
Name:
  Url: http://B
Name:
  Language:
    Code: en-gb
    Country: gb

```

如果按列存，就会把它拆成：

```

DocId
Links.Forward
Links.Backward
Name.Url
Name.Language.Code
Name.Language.Country

```

这样查询 **Name.Language.Country** 时只读这一列，确实省 I/O。但问题是：只看到 **Country** 这一列时，怎么知道某个值属于哪个 **record**、哪个 **Name**、哪个 **Language**？

所以 Dremel 给每个列值附加两个标签：

```
(value, r, d)
```

其中：

r = repetition level，重复层级 **d = definition level**，定义层级

PPT中明确写：Dremel 给每个 value 增加两个整数标签，r 表示 repetition level，d 表示 definition level。

4. r / d 一句话定义

r: repetition level 表示当前值是从路径上的哪个 **repeated** 字段 开始重复的。它主要回答：这是新 record，还是同一个 record 里的新 Name / 新 Language？

d: definition level 表示当前值所在路径上那些可能不存在的字段，也就是 **optional** 或 **repeated** 字段，实际出现了几层。它主要回答：这个值到底定义到了哪一层？是真有值，还是某一层缺失导致 NULL？

PPT原意是：r 表示 value 在字段路径上的哪个 repeated field 发生了重复；d 表示路径中可能 undefined 的字段有多少个实际存在。

考试写法： Repetition level 表示当前值相对于前一个值，从哪一个 repeated 字段开始重复，用于区分新记录、新 Name 或新 Language。Definition level 表示字段路径上 optional 或 repeated 字段实际存在到哪一层，用于区分真实值和由于某层缺失产生的 NULL。

5. d 怎么赋值：Definition Level

先看字段路径里有哪些 **可能不存在** 的节点。一般来说，**optional** 和 **repeated** 都算一层 **definition**；required 不增加 definition level。

例1: **Name.Language.Code**

路径：

```
Document.required  
-> Name.repeated  
-> Language.repeated  
-> Code.required
```

其中可能不存在的是：

```
Name      repeated  
Language  repeated
```

Code 是 required, 所以不额外加一层。

因此:

Name.Language.Code 的最大 d = 2

含义:

d = 0: 连 Name 都没有
d = 1: Name 有, 但 Language 没有
d = 2: Name 和 Language 都有, 因为 Code required, 所以 Code 有真实值

所以 Code 列中:

en-us	d=2	
en	d=2	
NULL	d=1	// 有 Name, 但没有 Language, 所以没有 Code
en-gb	d=2	
NULL	d=1	

例2: Name.Language.Country

路径:

```
Document.required  
-> Name.repeated  
-> Language.repeated  
-> Country.optional
```

可能不存在的是:

Name	repeated
Language	repeated
Country	optional

因此:

Name.Language.Country 的最大 d = 3

含义:

```
d = 0: Name 都没有
d = 1: Name 有, 但 Language 没有
d = 2: Name 和 Language 有, 但 Country 没有
d = 3: Name、Language、Country 都有, Country 是真实值
```

所以 Country 列中:

```
us      d=3    // Country 有真实值
NULL    d=2    // Language 有, 但 Country 缺失
NULL    d=1    // Name 有, 但 Language 缺失
gb      d=3
NULL    d=1
```

d 判题口诀: 沿路径数 **optional / repeated**, 存在几层就是 **d**; 如果 **d** 小于最大 **d**, 就说明某层缺失, 值是 **NULL**。

6. r 怎么赋值: Repetition Level

r 只和路径上的 **repeated** 字段有关。它表示“当前值和前一个值相比, 是从哪一层 **repeated** 字段开始重复的”。

还是看 **Name.Language.Code** 或 **Name.Language.Country**:

路径上的 **repeated** 字段有两个:

```
Name      repeated  -> level 1
Language   repeated  -> level 2
```

再加上 **record** 开始:

```
record     -> r = 0
Name       -> r = 1
Language   -> r = 2
```

含义:

```
r = 0: 新 record
r = 1: 同一个 record 里, 开始一个新的 Name
r = 2: 同一个 Name 里, 开始一个新的 Language
```

用 PPT 示例的 **Name.Language.Code** 列:

value	r	d
en-us	0	2
en	2	2
NULL	1	1
en-gb	1	2
NULL	0	1

解释：

en-us, r=0：第一条记录的第一个 Name 的第一个 Language。**en, r=2**：还是同一个 Name，只是多了一个 Language。**NULL, r=1**：同一个 record 里新的 Name，但这个 Name 没有 Language。**en-gb, r=1**：同一个 record 里又一个新的 Name，这个 Name 有 Language。**NULL, r=0**：新 record，里面有 Name，但没有 Language。

r 判题口诀：新 record, r=0；同 record 新 Name, r=1；同 Name 新 Language, r=2。

7. 关键列：Name.Language.Code

这是 PPT 重点页，直接背表：

Name.Language.Code

value	r	d
en-us	0	2
en	2	2
NULL	1	1
en-gb	1	2
NULL	0	1

解释版：

en-us：

第一条 record 开始，所以 r=0；
Name 和 Language 都存在，Code required，所以 d=2。

en：

同一个 Name 下的第二个 Language，所以 r=2；
Name 和 Language 都存在，所以 d=2。

NULL：

同一个 record 下的新 Name，所以 r=1；
这个 Name 没有 Language，所以 d=1。

en-gb：

同一个 record 下的新 Name，所以 r=1；
Name 和 Language 都存在，所以 d=2。

NULL:

新 record, 所以 $r=0$;

这个 record 里有 Name, 但 Name 没有 Language, 所以 $d=1$ 。

考试写法: 对于 **Name.Language.Code**, 路径中有两个 repeated 字段: Name 和 Language, 因此 r 的最大值为 2; 路径中可能缺失的字段也是 Name 和 Language, Code 是 required, 因此 d 的最大值为 2。 $r=0$ 表示新 record, $r=1$ 表示同一 record 中新的 Name, $r=2$ 表示同一 Name 中新的 Language; $d=2$ 表示 Code 存在, $d=1$ 表示 Name 存在但 Language 缺失。

8. 关键列: **Name.Language.Country**

也直接背表:

Name.Language.Country

value	r	d
us	0	3
NULL	2	2
NULL	1	1
gb	1	3
NULL	0	1

解释版:

us:

新 record, 所以 $r=0$;

Name、Language、Country 都存在, 所以 $d=3$ 。

NULL:

同一个 Name 下的新 Language, 所以 $r=2$;

Language 有, 但 Country 这个 optional 字段缺失, 所以 $d=2$ 。

NULL:

同一 record 下的新 Name, 所以 $r=1$;

Name 有, 但 Language 没有, 所以 $d=1$ 。

gb:

同一 record 下的新 Name, 所以 $r=1$;

Name、Language、Country 都存在, 所以 $d=3$ 。

NULL:

新 record, 所以 $r=0$;

Name 有, 但 Language 没有, 所以 $d=1$ 。

注意: **Code** 和 **Country** 的 r 一样, 因为它们路径上的 repeated 字段一样, 都是 Name 和 Language。区别在于 **d 最大值不同**: Code required, 最大 $d=2$; Country optional, 最大 $d=3$ 。

9. 其他列的 r/d 速查

DocId

路径：

```
Document -> DocId.required
```

没有 optional，也没有 repeated，所以：

```
最大 r = 0  
最大 d = 0
```

表：

DocId		
value	r	d
10	0	0
20	0	0

Links.Forward

路径：

```
Document  
-> Links.optional  
-> Forward.repeated
```

可能缺失字段：Links、Forward，所以最大 d=2。repeated 字段：Forward，所以最大 r=1。

表：

Links.Forward		
value	r	d
20	0	2
40	1	2
60	1	2
80	0	2

解释：

20: 新 record, r=0; Links/Forward 都存在, d=2
 40: 同一 record 下 Forward 重复, r=1
 60: 同一 record 下 Forward 重复, r=1
 80: 新 record, r=0

Links.Backward

表:

Links.Backward

value	r	d
NULL	0	1
10	0	2
30	1	2

解释:

NULL:

第一条 record 有 Links, 但没有 Backward, 所以 d=1。

10:

第二条 record 开始, 所以 r=0; Links 和 Backward 都存在, d=2。

30:

同一 record 下 Backward 重复, 所以 r=1; d=2。

Name.Url

路径:

Document
 -> Name.repeated
 -> Url.optional

可能缺失字段: Name、Url, 所以最大 d=2。repeated 字段: Name, 所以最大 r=1。

表:

Name.Url

value	r	d
http://A	0	2
http://B	1	2

NULL	1	1
http://C	0	2

解释：

http://A:
新 record, 第一个 Name, 有 Url。

http://B:
同一 record 下新的 Name, 有 Url, 所以 $r=1, d=2$ 。

NULL:
同一 record 下新的 Name, 但 Url 缺失, 所以 $r=1, d=1$ 。

http://C:
新 record, 第一个 Name, 有 Url, 所以 $r=0, d=2$ 。

10. r/d 计算题统一步骤

考试看到让你填 r/d, 就按这四步：

1. 写出字段路径。
2. 标出路径上的 repeated 字段, 决定 r 的层级。
3. 标出路径上的 repeated + optional 字段, 决定 d 的最大值。
4. 按实际记录逐个值判断：
 - 是新 record, $r=0$;
 - 是同 record 新的外层 repeated, $r=$ 对应外层;
 - 是同外层里新的内层 repeated, $r=$ 对应内层;
 - d 看路径实际存在到哪一层。

模板句：

r 看重复从哪一层开始, **d** 看定义到哪一层。

或者更短：

r 管“重复层级”
d 管“缺失层级”

11. Encoding：Dremel 怎么真正存

PPT里说每一列按 block 存储, 每个 block 包含 repetition levels、definition levels 和压缩后的字段值；NULL 不显式存储, 任何小于最大 definition level 的 d 都表示 NULL；level 会被打包成 bit sequence。

重点：表格里写 **NULL** 是为了讲解结构，实际存储时不一定真的存一个字符串 NULL。Dremel 通过 d 判断这里是缺失值。

考试写法：Dremel 的每一列被存储为多个 block，每个 block 包含 repetition level、definition level 和压缩后的字段值。NULL 通常不显式存储，而是通过 definition level 表示：当某个值的 d 小于该字段路径的最大 definition level 时，说明路径中某一层缺失，因此对应值为 NULL。

12. Record Assembly FSM 是什么

FSM = Finite State Machine, 有限状态机。

它用来把列式数据重新拼回记录。PPT中 Record assembly FSM 页面说明：FSM 的状态与字段路径有关，边上标的是 repetition level；对于面向记录的数据处理，如 MapReduce，FSM 会对每条 record 从开始状态走到结束状态一次。

你可以这样理解：

r 决定回退到哪一层，再从那一层继续拼；**d** 决定这条路径实际生成到哪一层。

比如读取 **Name.Language.Country** 时：

```
r=0: 新 Document  
r=1: 同一个 Document 里开新的 Name  
r=2: 同一个 Name 里开新的 Language
```

再看 d：

```
d=3: Country 有真实值  
d=2: Language 有，但 Country 没有  
d=1: Name 有，但 Language 没有
```

13. 基于 FSM 拼回表：通用规则

考试如果给列式数据让你拼回嵌套结构，就按这个规则写。

1. 读当前列值的 (value, r, d)。
2. 如果 r=0，说明开始一条新 record。
3. 如果 r>0，根据 r 回退到对应 repeated 层：
r=1: 开新的 Name
r=2: 开新的 Language
4. 根据 d 判断结构定义到哪一层：
d=max: 叶子字段有真实值
d=max-1 或更小: 某层缺失，填 NULL 或不生成叶子字段
5. 持续读取，直到下一个 r=0 开启下一条 record。

答题模板：利用 FSM 拼回记录时，先根据 repetition level 判断当前值是新记录还是某个 repeated 字段的新实例；再根据 definition level 判断字段路径实际存在到哪一层。如果 d 达到最大 definition level，则填入真实值；如果 d 小于最大值，则说明路径中某个 optional/repeated 字段缺失，只生成已定义到的结构。

14. 拼回例子：只看 DocId 和 Name.Language.Country

给定两列：

DocId

value	r	d
10	0	0
20	0	0

Name.Language.Country

value	r	d
us	0	3
NULL	2	2
NULL	1	1
gb	1	3
NULL	0	1

拼回逻辑：

第一行 Country: us, r=0, d=3

r=0: 新 record, 对应 DocId=10
d=3: Name、Language、Country 都存在

拼出：

```
DocId: 10
Name:
  Language:
    Country: us
```

第二行: NULL, r=2, d=2

r=2: 同一个 Name 里新的 Language
d=2: Name 和 Language 存在, 但 Country 缺失

拼出：

```
Name:
Language:
Country: us
Language:
Country: NULL / absent
```

第三行: **NULL, r=1, d=1**

```
r=1: 同一个 record 里新的 Name
d=1: Name 存在, 但 Language 缺失
```

拼出：

```
Name:
// no Language
```

第四行: **gb, r=1, d=3**

```
r=1: 同一个 record 里新的 Name
d=3: Name、Language、Country 都存在
```

拼出：

```
Name:
Language:
Country: gb
```

第五行: **NULL, r=0, d=1**

```
r=0: 新 record, 对应 DocId=20
d=1: Name 存在, 但 Language 缺失
```

拼出：

```

DocId: 20
Name:
  // no Language

```

最后结构大致是：

```

DocId: 10
Name:
  Language:
    Country: us
  Language:
    Country: NULL
Name:
  // no Language
Name:
  Language:
    Country: gb

DocId: 20
Name:
  // no Language

```

注意：如果题目要求严格还原原 PPT 记录，并且同时给了 **Name.Language.Code**，那第二个 Language 有 **Code=en**，只是 **Country** 缺失；只读 Country 时只能知道 Country 缺失，但不能知道 Code 的具体值。

15. 拼回例子：Name.Language.Code

给表：

Name.Language.Code

value	r	d
en-us	0	2
en	2	2
NULL	1	1
en-gb	1	2
NULL	0	1

拼回：

```

r=0,d=2,value=en-us:
  新 record, 新 Name, 新 Language, Code=en-us

r=2,d=2,value=en:
  同一 Name 下新的 Language, Code=en

```

```

r=1,d=1,NULL:
  同一 record 下新的 Name, 但 Language 缺失, 所以没有 Code

r=1,d=2,value=en-gb:
  同一 record 下新的 Name, 新 Language, Code=en-gb

r=0,d=1,NULL:
  新 record, 有 Name, 但 Language 缺失, 所以没有 Code

```

拼出简化结构:

```

Record 1:
  Name 1:
    Language 1:
      Code: en-us
    Language 2:
      Code: en
  Name 2:
    // no Language
  Name 3:
    Language 1:
      Code: en-gb

Record 2:
  Name 1:
    // no Language

```

16. Code 和 Country 的区别: 最容易考的点

`Name.Language.Code` 和 `Name.Language.Country` 路径很像, 但:

```

Code 是 required
Country 是 optional

```

所以:

```

Code 最大 d = 2
Country 最大 d = 3

```

它们的 r 一样:

```

r=0 新 record
r=1 新 Name

```

r=2 新 Language

它们的 d 不一样：

```
Code:
  d=2 才有 Code
  d=1 表示 Name 有但 Language 没有

Country:
  d=3 才有 Country
  d=2 表示 Language 有但 Country 没有
  d=1 表示 Name 有但 Language 没有
```

考试写法：Code 是 required 字段，因此只要 Name 和 Language 存在，Code 就存在，最大 definition level 为 2；Country 是 optional 字段，即使 Name 和 Language 存在，Country 也可能缺失，因此最大 definition level 为 3。二者路径上的 repeated 字段相同，所以 repetition level 的含义相同。

17. 本章高频简答模板

1. Dremel 为什么需要 r/d? Dremel 将嵌套记录按列存储以减少查询 I/O，但列式存储会打散原有的嵌套结构。为了在只读取部分列时仍能恢复记录结构，Dremel 为每个值保存 repetition level 和 definition level。r 表示重复从哪一层开始，d 表示字段路径实际定义到哪一层。

2. repetition level 是什么? Repetition level 表示当前值相对于前一个值，是从字段路径上的哪个 repeated 字段开始重复的。它用于区分新 record、同一 record 中的新 Name、同一 Name 中的新 Language 等结构重复关系。

3. definition level 是什么? Definition level 表示字段路径中 optional 或 repeated 字段实际存在了多少层。若 d 达到该字段的最大 definition level，则叶子字段有真实值；若 d 小于最大值，则说明路径中某层缺失，对应值为 NULL 或 absent。

4. 为什么 Name.Language.Code 最大 d 是 2? 因为该路径中可能缺失的字段是 repeated 的 Name 和 repeated 的 Language，而 Code 是 required，不额外增加 definition level。因此最大 d 为 2，表示 Name 和 Language 都存在时 Code 必然存在。

5. 为什么 Name.Language.Country 最大 d 是 3? 因为该路径中可能缺失的字段包括 repeated 的 Name、repeated 的 Language 和 optional 的 Country。Country 自身可缺失，因此最大 definition level 为 3。

6. FSM 如何拼回记录? FSM 根据 repetition level 判断当前值是新 record 还是某个 repeated 字段的新实例，再根据 definition level 判断字段路径实际存在到哪一层。r 控制结构回退和重复，d 控制是否填入真实值或生成缺失结构。

18. 本章易混点

r 不是“重复次数”。 r 表示从哪一层 repeated 字段开始重复，不是第几个值。

d 不是“深度总层数”。 d 只数路径上可能缺失的字段，也就是 optional 和 repeated；required 不算缺失层。

NULL 不一定真实存储。 讲解表里写 NULL 是为了表示结构缺失，实际存储中通常靠 definition level 表示 NULL。

Code 和 Country 的 r 一样，d 不一样。 因为它们 repeated 路径一样，但 Country 是 optional，Code 是 required。

r=0 一般表示新 record。 看到 r=0，通常就要开启下一条记录。

d 达不到最大值，说明叶子值不存在。 比如 Country 最大 d=3，d=2 表示 Language 存在但 Country 缺失。

19. 本章看到题目怎么写

看到“**解释 r/d**”：写 r 管重复层级，d 管定义/缺失层级。

看到“**给 Code 填 r/d**”：路径是 Name repeated -> Language repeated -> Code required，最大 r=2，最大 d=2。

看到“**给 Country 填 r/d**”：路径是 Name repeated -> Language repeated -> Country optional，最大 r=2，最大 d=3。

看到“**为什么列式还能拼回嵌套结构**”：写每个值带 r/d，r 保留重复关系，d 保留缺失关系。

看到“**基于 FSM 拼回表**”：先看 r，新 record / 新 Name / 新 Language；再看 d，判断真实值还是某层缺失。

看到“**计算题**”：先写路径，再标 repeated 层级，再标 optional/repeated 的 definition 层级，最后逐行填表。